第12讲 机器是怎样学习的？
—样本-训练与分类

李玉华

华中科技大学计算机学院

idcliyuhua@hust.edu.cn

从AlphaGo看人工智能

AlphaGo是什么?



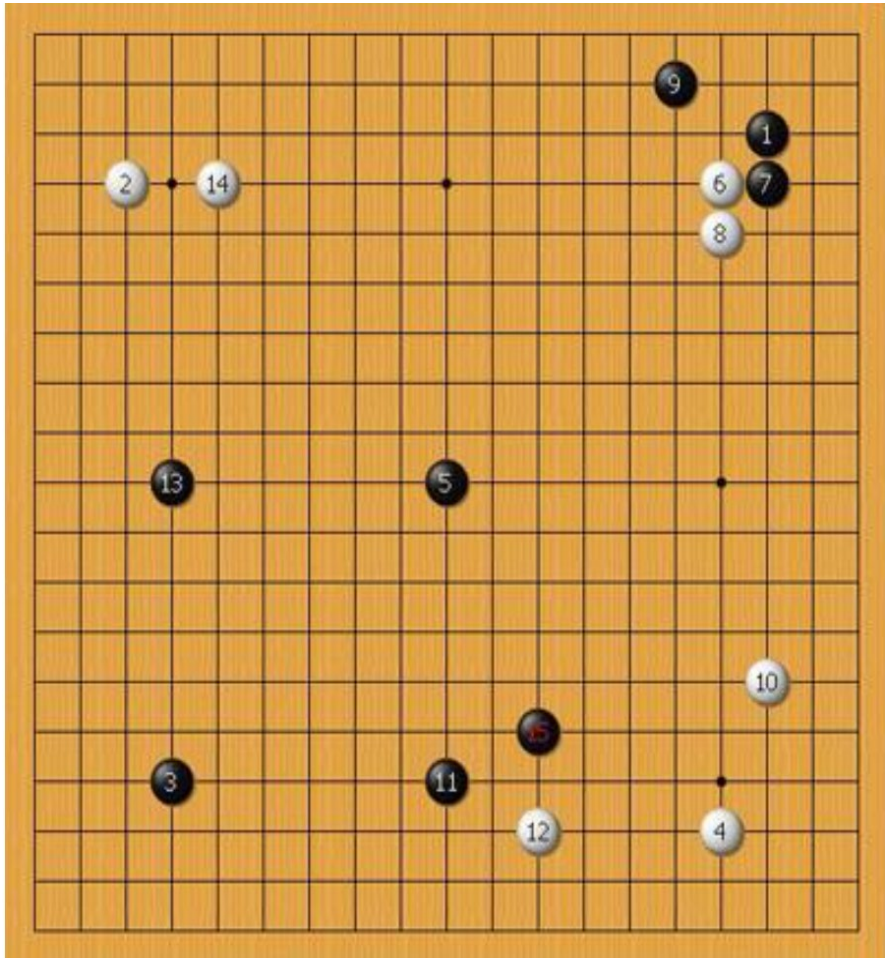
AlphaGo是首个击败人类围棋选手职业冠军的计算机程序

【思考】

- AlphaGo战胜人类围棋世界冠军为什么引发了人工智能的高关注度?
- AlphaGo使用了什么样的创新技术，这些技术对人工智能发展有什么意义?

从AlphaGo看人工智能

围棋规则及行棋复杂性



围棋

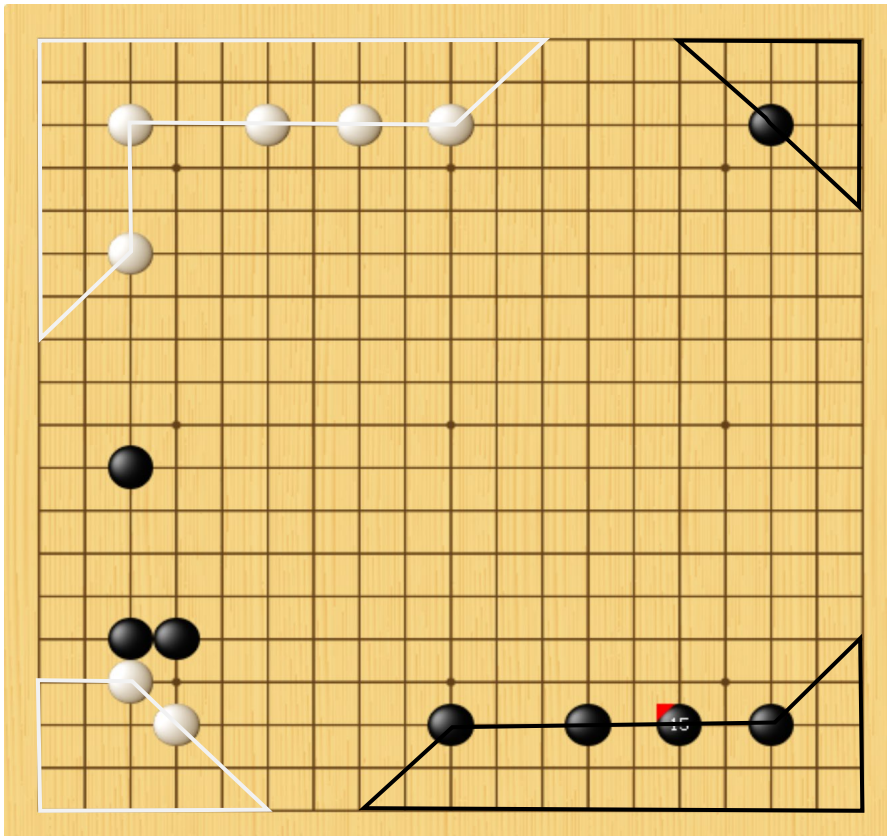
- **棋盘**：19*19的平行线构成，形成 361个交叉点，交叉点放置棋子。
- **对局**：双方各执一色棋子，轮流下子于交叉点。
- **胜负**：围住空间多的一方获胜。
- **复杂性**：假如用1,2,...,361来表示每一个交叉点即棋子位置，则一盘棋局就是这些棋子位置的一种组合。而棋盘上所有可能位置组合**(枚举)**多达$10^{170}(=3^{361})$：361个位置，每个位置黑子、白子、无子3种状态），是一种非常复杂的游戏。

可观测宇宙的直径达920亿光年，包含不计其数的星系，估算出的原子总量也只有10^{80}个



从AlphaGo看人工智能

围棋的智能问题



围棋形势判断

- **围棋待行棋位置的决策**
  - ✓ 轮黑方或白方下子时，选择哪一个交叉点落子才能取胜
- **围棋形势的判断**
  - ✓ 行棋到某一状态时，对围棋胜负局面的判断

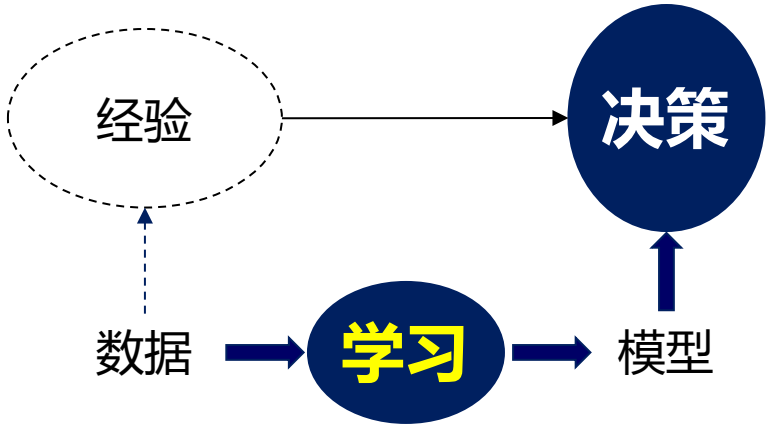
机器是怎样通过学习提高智能的?

围棋对弈与人工智能和机器学习有什么关系?

机器学习与人工智能

机器学习相关内容概述

- 机器学习是一门从数据中研究算法的多领域交叉学科。
- 机器学习研究计算机如何模拟或实现人类的学习行为
- 机器学习从以往的经验中得到数据，通过学习构建模型，预测新数据，并提供对问题的决策支持
- 典型方法：决策树、随机森林、人工神经网络、贝叶斯学习、关联规则学习、深度学习等

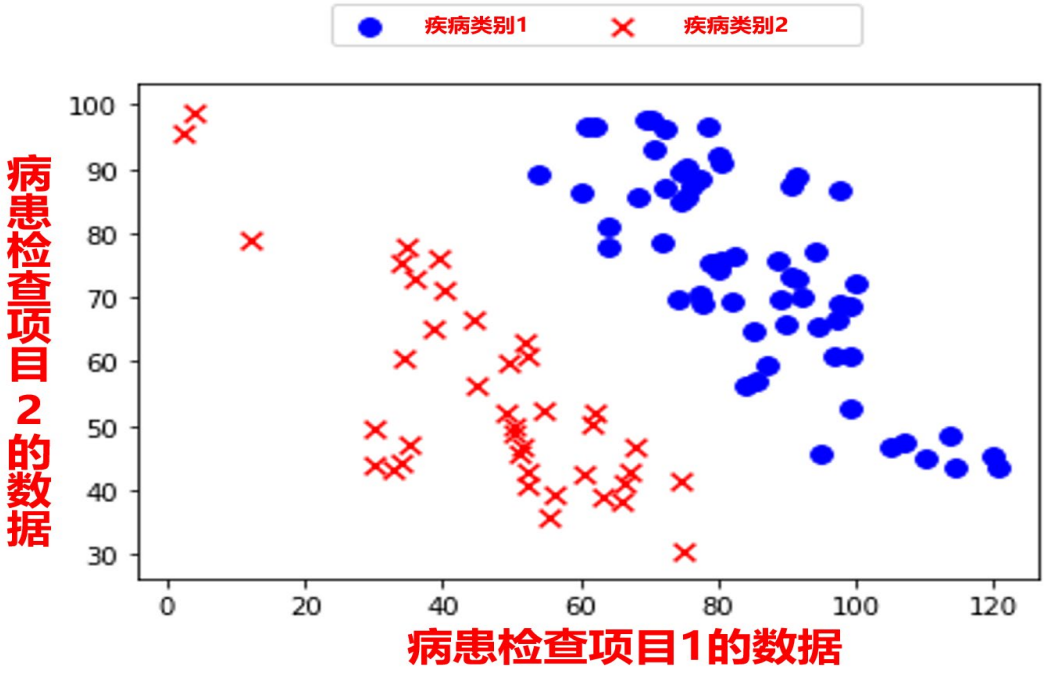


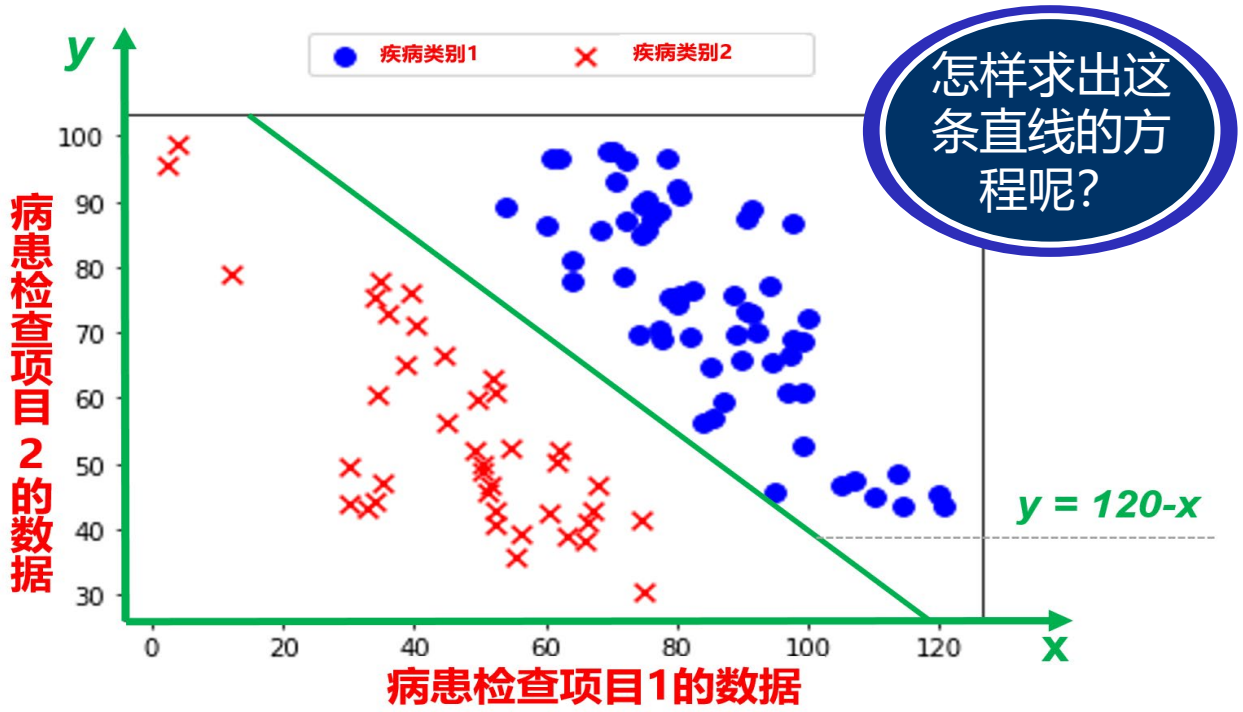


两特征两类别分类问题

已知模型，对【数据】进行分类

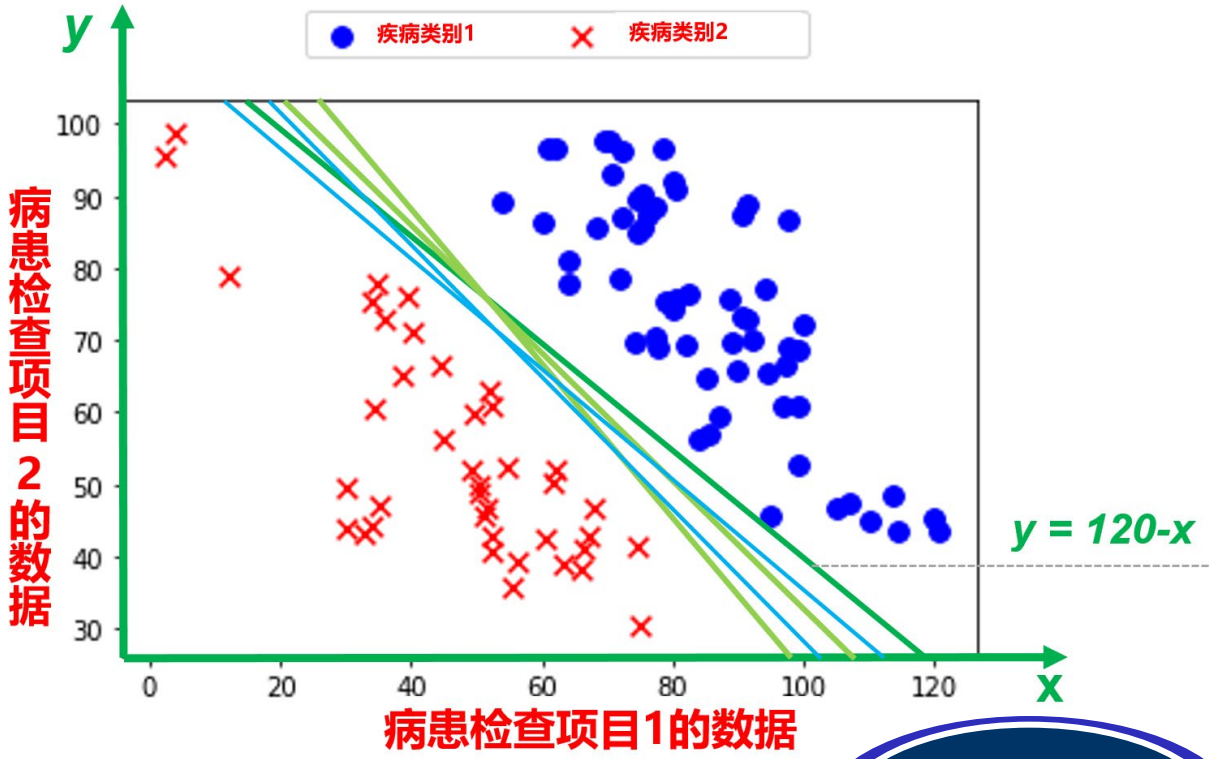
【示例】有100个病患，已知每个病患的两个项目的检查数据，且每个病患的诊断结果（疾病类别1或疾病类别2）已知。问：如何根据这些数据反推出疾病诊断的标准并用于对未分类病患的疾病诊断？





两特征两类别分类问题

已知样本数据及其分类结果，反求模型：线性回归（拟合）



枚举-计算- 验证-优化算法

算法：最小二乘法、梯度下降法（略）

待求方程形式：$y=wx+b$

$$\hat{y}=wx+b$$

$$L=\frac{1}{n}\sum_{i=1}^{n}\left(\hat{y}^{(i)}-y^{(i)}\right)^2$$

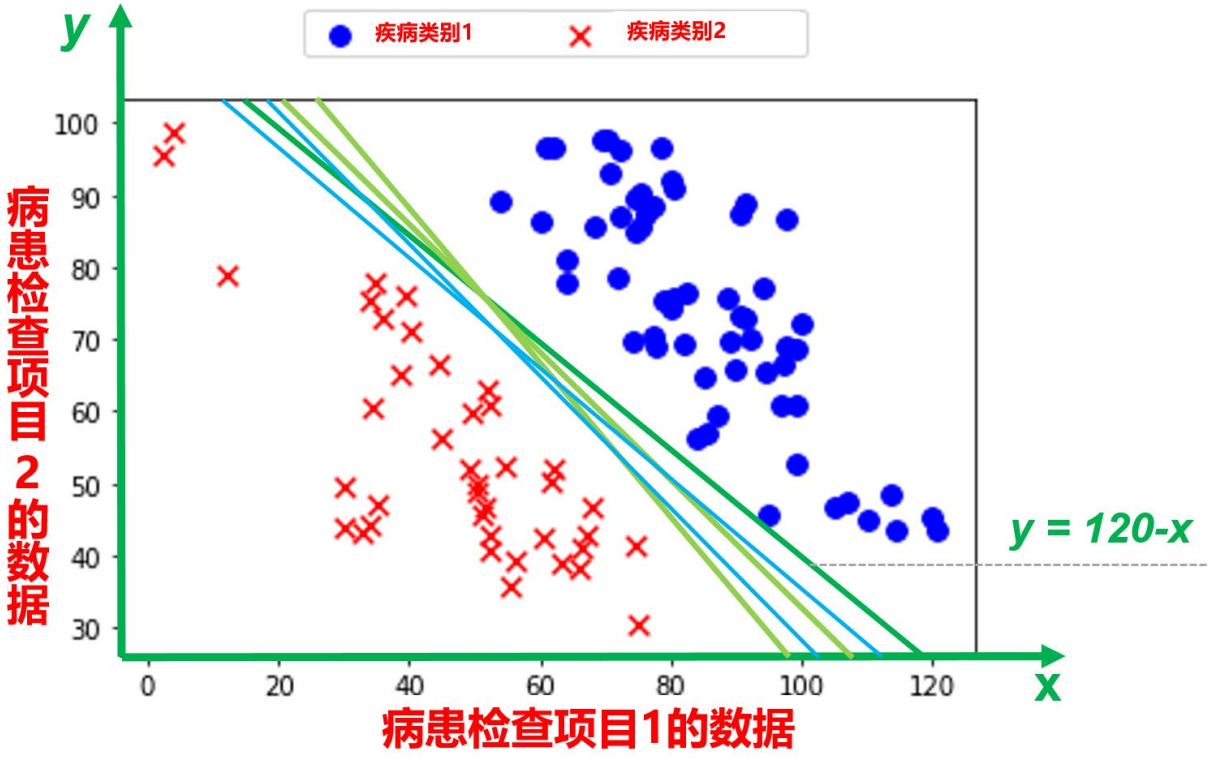
$$L(w,b)=\frac{1}{n}\sum_{i=1}^{n}\left(wx^{(i)}+b-y^{(i)}\right)^2$$

其中$<x^{(i)},y^{(i)}>$为样本点，而 $\hat{y}$ 为按方程计算的点

【线性回归】**枚举**w和b，使【损失函数】L值最小

两特征 vs. 多特征 两类别分类问题

多特征线性方程形式



两特征方程形式：

$$y = w_1 x + b$$

多特征方程形式：

$$y = w_1 x_1 + w_2 x_2 + \ldots + w_{m-1} x_{m-1} + b$$

模型形式一定是线性的吗？

两特征两类别分类问题

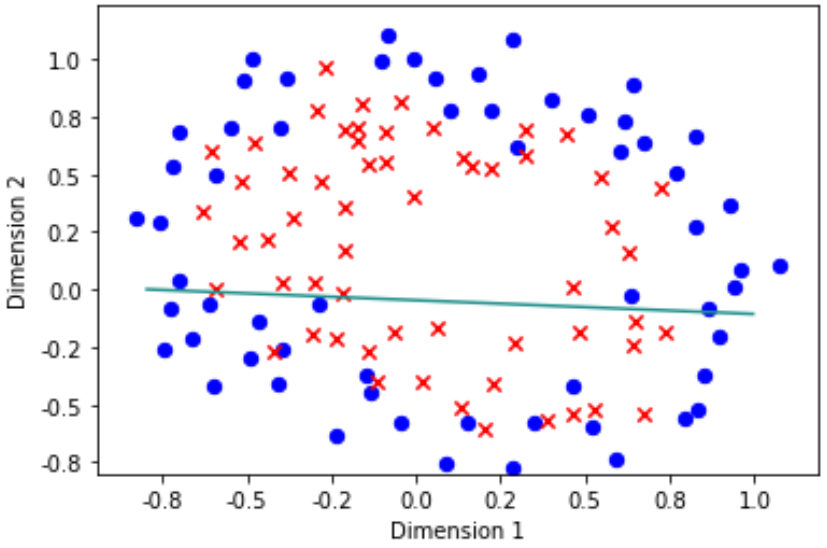
曲线拟合分类问题：线性分类 vs. 非线性分类

理想很丰满，现实很骨感--对于更复杂的数据，如何求解?

数学是不是很有用呢?
哪些函数形式能产生
什么形式的曲线?

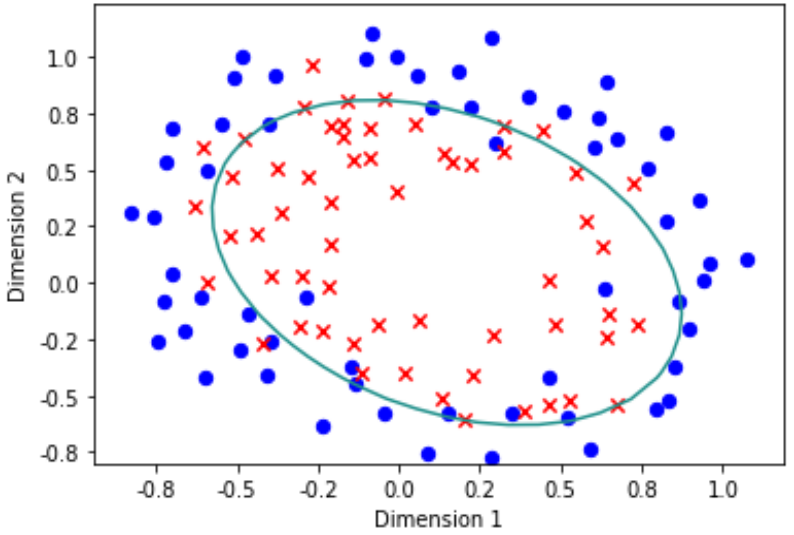
- **模型假设?**

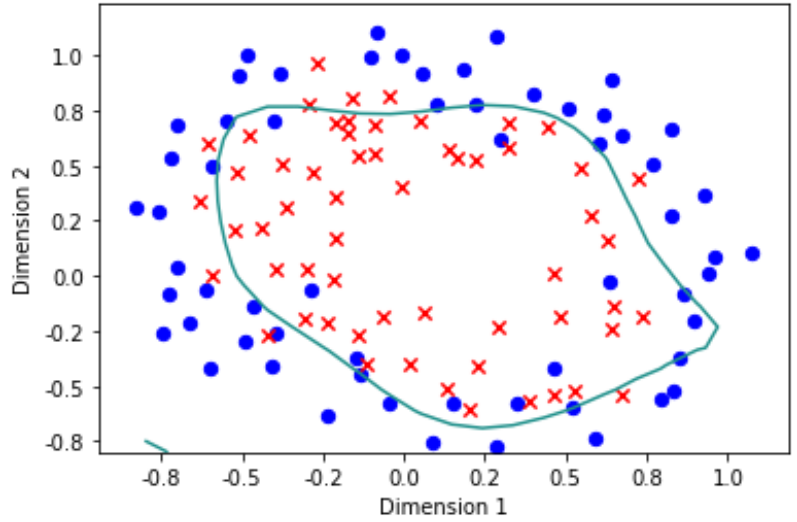
---仍用直线分割（分类）？



模型假设?

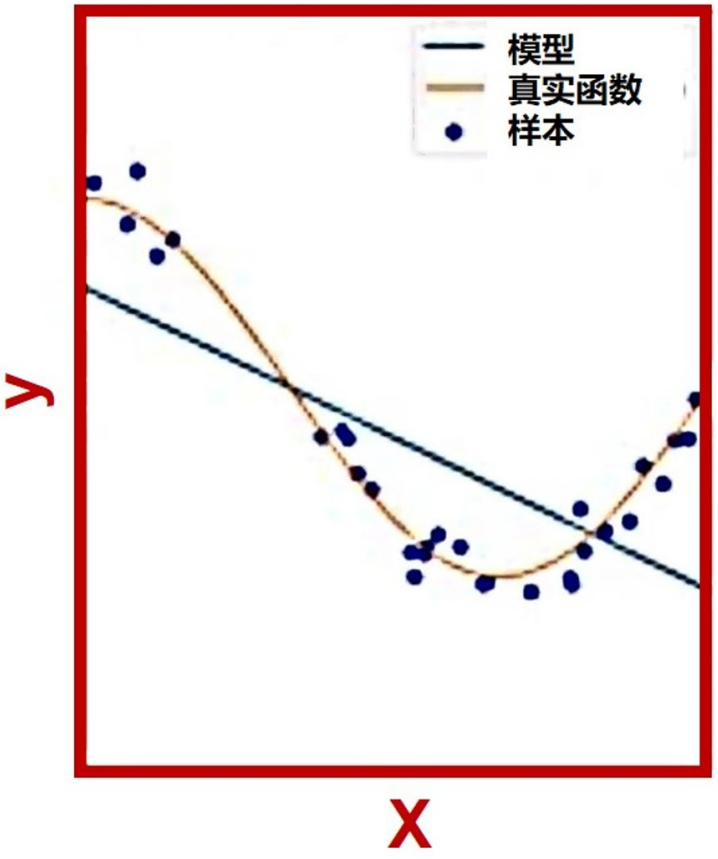
---用曲线如何?



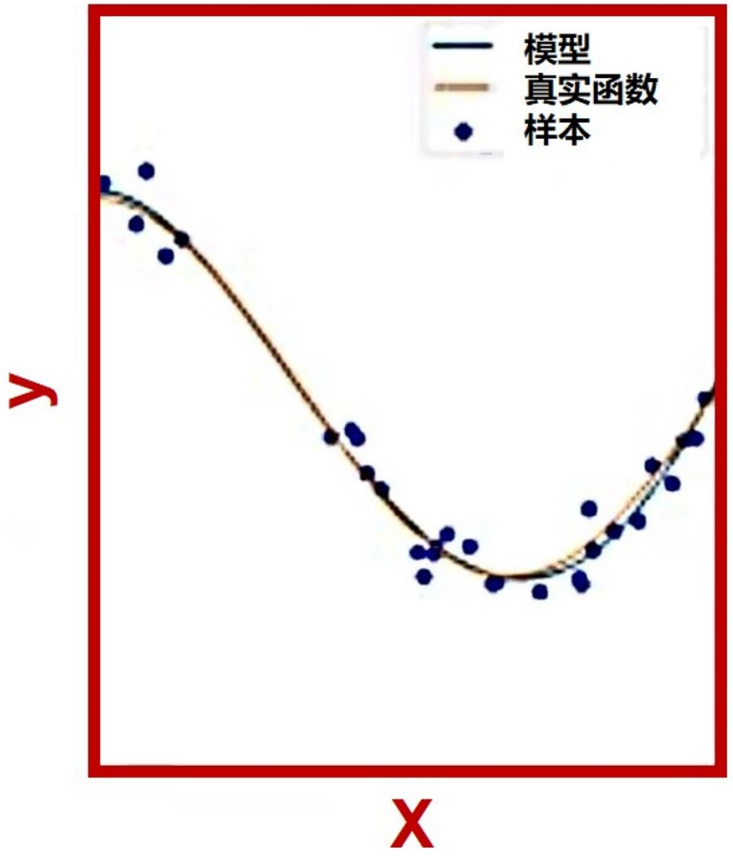


两特征两类别分类问题

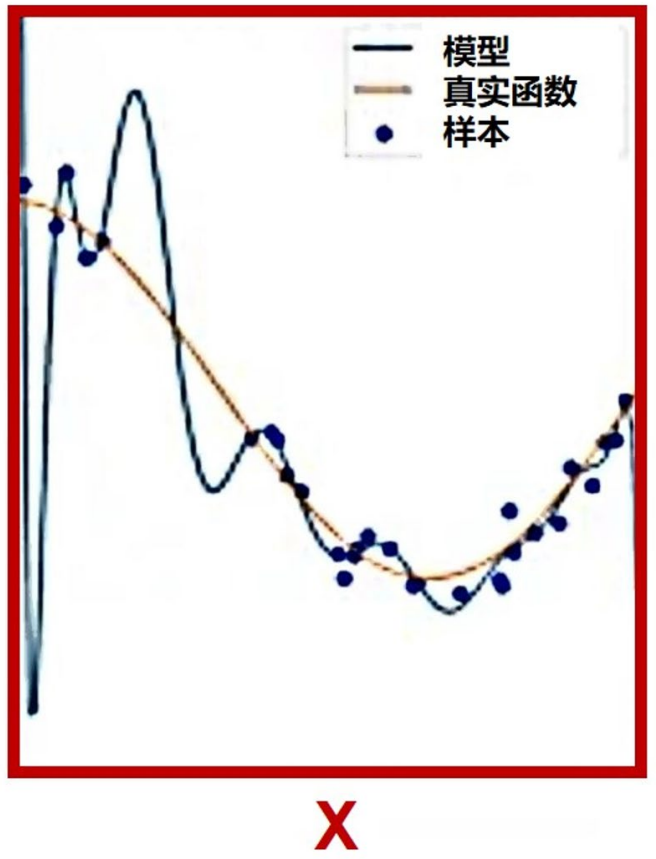
曲线拟合存在的问题：【欠拟合】与【过拟合】



$$y = \theta_0 + \theta_1 x$$



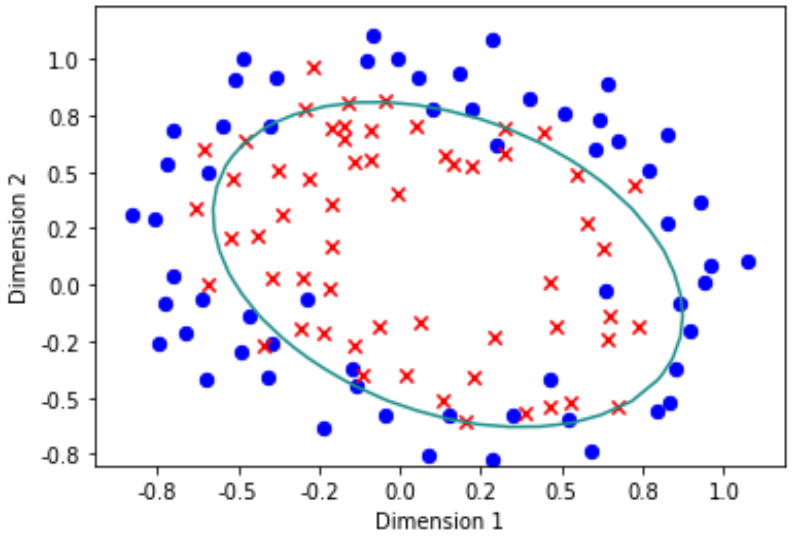
$$y = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$$

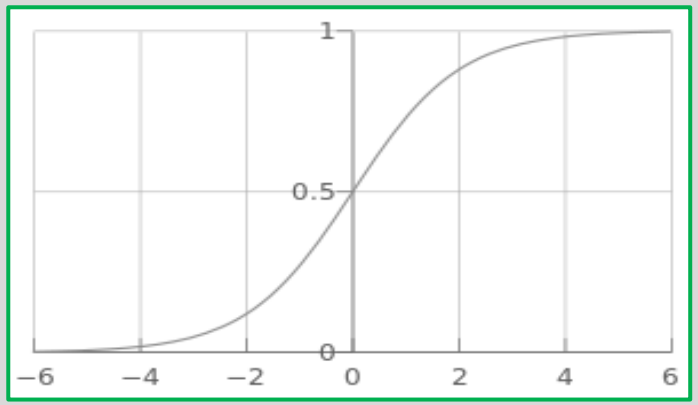


$$y = \sum_{n=0}^{N} \theta_n x^n$$

如何判断边界内外

逻辑回归：将结果映射为0和1的函数





Sig***moid***函数：$g(z)=\frac{1}{1+e^{-z}}$

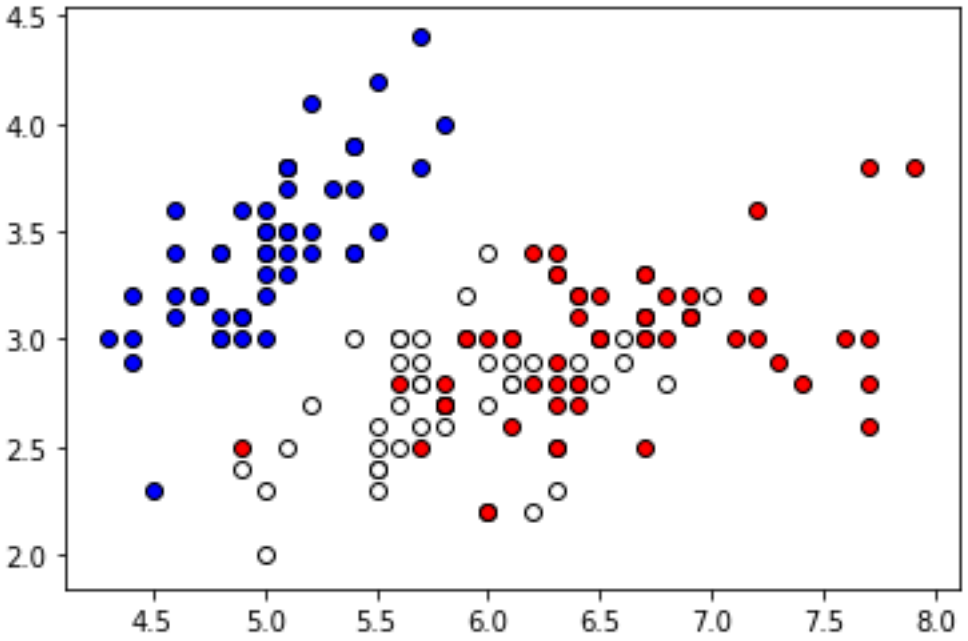
$$z = w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_2^2$$

$$\boldsymbol{y(z) = \frac{1}{1+e^{-z}}}$$

多类别分类问题

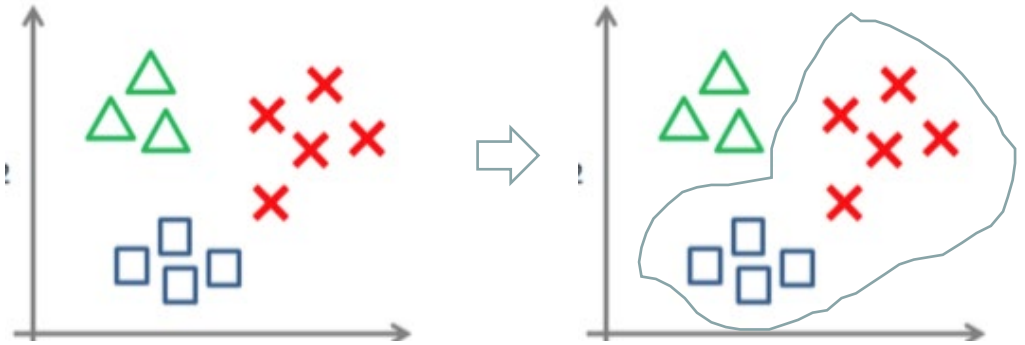
多类别分类问题

推广到多类问题，如何求解?



- **多类分类问题可以转化为两类分类问题进行解决**

--例如将其中一个类视为正类、其它类统一视为负类ONE-VS-REST模式)



问题：假设采用ONE-VS-REST模式，且共有N个类，则需要构建多少个二类分类器?

什么是机器学习

基本概念与过程

分类问题

已明确**分类结果(标签)**的
样本数据集合
$\{S_i,<标签>\}$
其中每个S_i都有n个特征值
$S_i:(x_1,x_2,\cdots x_n)$

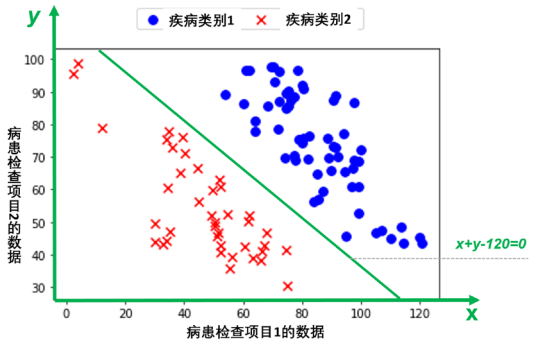
训练/学习
已知分类结果,反求方程参数$w_1,w_2,\cdots w_n$

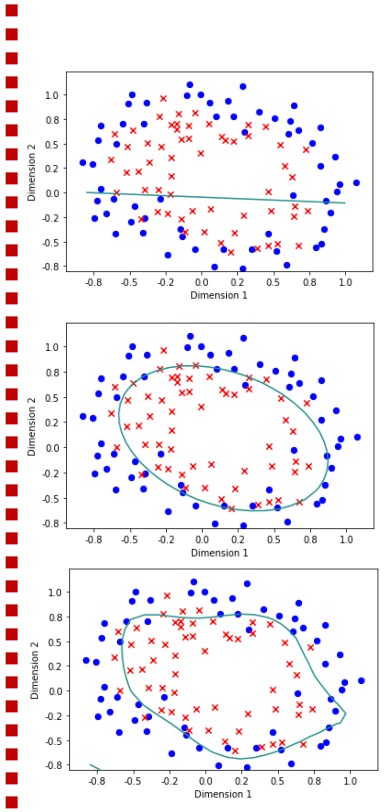
模型形式
具有待确定参数$w_1,w_2,\cdots w_n$的关于$x_1,x_2,\cdots x_n$的一组方程组

已标注标签的
样本数据集合
$\{S_i,<标签>\}$,
其中每个S_i都有n个特征值
$S_i:(x_1,x_2,\cdots x_n)$

调试/开发
(调优:改变学习过程的一些参数,如迭代次数、收敛程度等)

模型
具有明确参数的
$w_1,w_2,\cdots w_n$
的一组方程组





待分类的
数据
$S:(x_1,x_2,\cdots x_n)$

分类/识别
(已知方程求分类结果)

结果
S属于哪一类别的判断